

智能体沙箱设计思路

当你把 Microsandbox 的 MCP Server 接入智能体后，它们之间会发生一场“自动握手”。

1. 自动发现机制 (Handshake)

当你启动智能体（如 Claude 或你基于 MCP 开发的 Agent）时：

- 智能体会询问：“嘿，Microsandbox，你现在能提供哪些工具？”
- Microsandbox 会回传：一个标准的 JSON Schema。这个 Schema 包含了 `run_code`、`run_command` 的名称、参数定义（比如 `code` 字符串）以及详细的功能描述（例如：“用于在安全的隔离环境中执行 Python 代码”）。
- 智能体自动更新：智能体内部的系统提示词（System Prompt）会自动增加这些工具的定义，它会“意识到”自己现在拥有了操作沙盒的能力。

1. 你唯一需要做的“提示词”是什么？

虽然工具是自动发现的，但为了让智能体更聪明、更主动地使用沙盒（像 Manus 那样），你通常需要在系统提示词中给它一点“性格”或“策略指南”：

示例系统提示词（System Prompt）：

“你现在拥有一个名为 `microsandbox` 的安全执行环境。当你遇到需要进行数学计算、数据分析、文件处理或验证代码逻辑的任务时，请优先在沙盒中编写并运行代码来获取答案，而不是仅凭记忆推断。如果运行报错，请利用报错信息进行自我修复并重新运行。”

1. 工具调用的全过程示意图

- 连接阶段：Agent 启动，通过 `tools/list` 自动获取 Microsandbox 的工具列表。
- 触发阶段：用户问：“帮我算一下这个复杂函数的导数。”
- 决策阶段：Agent 看到自己有 `run_code` 工具，决定生成 Python 代码。
- 执行阶段：Agent 发出 `tools/call` 请求。Microsandbox 在 200ms 内拉起 MicroVM，跑完代码，返回 `{"result": "..."}` 。
- 总结阶段：Agent 看到结果，整理成人类语言回复你。

1. 总结：你现在的操作路径

- 服务端：运行 `msb server start --dev`（它会准备好工具列表）。
- 客户端（Agent）：指向这个 MCP 服务的地址（如果是 Claude Desktop，直接改 JSON 配置）。

- 对话：你只需要直接下达任务，例如：“帮我分析这个 CSV 文件并画个折线图”。
 - 注：Agent 会自己发现并连续调用 `write_file` 和 `run_code` 来完成任务。

AI Agent 集成 Microsandbox 系统架构：

这个架构分为三个关键的逻辑阶段，图中的箭头和编号清晰地体现了这一点：

阶段一：准备与握手 (Setup & Handshake Phase)

- 图示位置：左上方的 AI Agent 与中间的 MSB_Server 之间的双向箭头 [A. 启动握手]。
- 流程：
 - 当你启动 AI Agent（如打开 Claude Desktop）时，它会根据配置文件启动 Microsandbox Server。
 - 关键动作：MSB_Server 主动向 Agent 发送一个“能力清单”（JSON Schema），告诉 Agent：“我这里有 `run_code` (跑代码) 和 `run_command` (跑命令) 等工具”。
 - Agent 自动将这些能力加入自己的 动态工具箱。这一步是自动的，你无需编写任何提示词来描述这些工具。

阶段二：思考与调用 (Decision & Execution Phase)

- 图示位置：从 User 到 Agent，再通过 [B. 任务执行] 箭头指向右侧。
- 流程：
 - 用户下达指令（如“分析数据”）。
 - Agent 的大模型内核进行思考，意识到需要运行 Python 代码来完成任务，于是决定调用工具箱里的 `run_code`。
 - Agent 将生成的代码通过 MCP 通道发送给 MSB_Server。

阶段三：隔离执行 (Isolation & Runtime Phase)

- 图示位置：右侧红色的 硬件级隔离执行区。
- 流程：
 - MSB_Server 接收请求，指挥底层的核心引擎。
 - 核心优势：引擎利用 KVM/HVF 硬件虚拟化技术，在 200毫秒内 拉起一个全新的、独立的微虚拟机 (MicroVM)。
 - 代码在这个“防弹玻璃房”里运行。即使代码包含恶意指令（如删除系统文件），也只能破坏这个临时的沙盒，绝对无法逃逸到你的宿主机。

- 运行结束后，结果被层层传回给 Agent，Agent 最终整理语言回复用户。默认情况下，这个 MicroVM 会立即销毁，不留痕迹。

